

LIVRABLE — Architecture de données pour un laboratoire de santé

Eugenia School — Data Architecture for AI

1. CAHIER DES CHARGES

1.1 Contexte

Un laboratoire de santé fictif souhaite centraliser l'ensemble de ses données médicales dans une architecture moderne, conteneurisée et scalable. Les données sont hétérogènes : certaines sont structurées (relations entre entités) et d'autres sont semi-structurées (contenu variable selon les consultations).

1.2 Besoins fonctionnels

#	Besoin	Description
F1	Gestion des médecins	Stocker id, prénom, nom, spécialité, hôpital, téléphone
F2	Gestion des patients	Stocker id, prénom, nom, date de naissance, genre, groupe sanguin, médecin référent
F3	Gestion des médicaments	Référencer id, nom, dosage, unité, catégorie
F4	Gestion des prescriptions	Lier une consultation (MongoDB), un médicament, une date et une durée
F5	Gestion des consultations	Enregistrer les symptômes et diagnostics sous forme de documents JSON

#	Besoin	Description
F6	Interface d'administration	Accéder aux bases via des interfaces graphiques (pgAdmin, Mongo Express)

1.3 Besoins techniques


#	Besoin	Technologie
T1	Stockage des données structurées	PostgreSQL (SQL, relations, contraintes d'intégrité)
T2	Stockage des données semi-structurées	MongoDB (NoSQL, documents JSON flexibles)
T3	Conteneurisation des services	Docker + docker-compose
T4	Interface d'administration PostgreSQL	pgAdmin
T5	Interface d'administration MongoDB	Mongo Express
T6	Monitoring des conteneurs	Portainer
T7	Ingestion automatisée des données	Scripts Python (psycpg2 + pymongo)

1.4 Contraintes

- Toutes les données doivent persister après un redémarrage des conteneurs (volumes Docker)
 - Les services doivent communiquer via un réseau Docker isolé
 - Aucun mot de passe ne doit être écrit en dur dans le code (fichier .env)
 - Le pipeline d'ingestion doit être idempotent (re-exécutable sans créer de doublons)
-

2. MODÈLE DE DONNÉES

2.1 Schéma SQL — PostgreSQL



2.2 Schéma NoSQL — MongoDB

Structure d'un document **consultations**

```

1  {
2      "consultation_id": "CONS0001",
3      "patient_id": "P8037",
4      "date": "2025-12-21",
5      "symptoms": "Lombalgie chronique irradiant dans la jambe gauche, paresthésies.",
6      "diagnosis": "Diabète de type 2 à confirmer – HbA1c demandée."
7  }
8

```

3. ARCHITECTURE DU PROJET

3.1 Structure des fichiers


labo-sante/

```

├── app/
|   ├── Dockerfile          # Image Python pour l'ingestion
|   ├── main.py             # Point d'entrée : lance les deux ingestions
|   ├── ingest_postgres.py  # Ingestion optimisée des CSV dans PostgreSQL
|   ├── ingest_mongo.py     # Ingestion optimisée du JSON dans MongoDB
|   └── requirements.txt    # Dépendances Python
├── data/
|   ├── data_small/         # ~84 061 lignes / 60 000 documents
|   ├── data_medium/       # ~840 061 lignes / 600 000 documents
|   └── data_large/         # ~8 400 061 lignes / 6 000 000 documents
├── docker-compose.yml      # Orchestration des 6 services
└── .env.example            # Modèle de configuration

```

3.2 Diagramme



4.Extraits commentés du docker-compose.yml

```
services:

# =====
# SERVICE 1 : PostgreSQL (base SQL)
# =====
postgres:
  image: postgres:15
  container_name: postgres
  environment:
    POSTGRES_USER: ${POSTGRES_USER}
    POSTGRES_PASSWORD: ${POSTGRES_PASSWORD}
    POSTGRES_DB: ${POSTGRES_DB}
  volumes:
    - postgres_data:/var/lib/postgresql/data # persistance des données
  networks:
    - labo_network
  ports:
    - "5432:5432"
  healthcheck:
    # Vérifie que PostgreSQL est prêt à accepter des connexions
    test: ["CMD-SHELL", "pg_isready -U ${POSTGRES_USER} -d ${POSTGRES_DB}"]
    interval: 10s # vérifie toutes les 10 secondes
    timeout: 5s # abandonne si pas de réponse en 5s
    retries: 5 # 5 tentatives avant de déclarer le service "unhealthy"
```

```
# =====
# SERVICE 2 : pgAdmin (interface PostgreSQL)
# =====
pgadmin:
  image: dpage/pgadmin4
  container_name: pgadmin
  environment:
    PGADMIN_DEFAULT_EMAIL: ${PGADMIN_EMAIL}
    PGADMIN_DEFAULT_PASSWORD: ${PGADMIN_PASSWORD}
  ports:
    - "5050:80" # expose pgAdmin on port 5050 of the host
  networks:
    - labo_network
  depends_on: # attend que PostgreSQL soit prêt avant de démarrer pgAdmin
    postgres:
      condition: service_healthy # attend que PostgreSQL soit vraiment prêt
```

5. Captures pgAdmin, Mongo Express, Portainer

localhost:8081/db/labo_sante/consultations

Mongo Express Database: labo_sante Collection: consultations

Viewing Collection: consultations

New Document New Index

Simple Advanced

Key Value String Find

Delete all 600000 documents retrieved

1 2 3 4 5 > >>

_id	consultation_id	patient_id	date	symptoms	diagnosis
6a39879b0447e59ecab0f221	CONS0001	P119875	2023-04-24	Dysurie, brûlures mictionnelles, douleur sus-publ...	Syndrome anxio-dépressif, trouble de l'adaptation.
6a39879b0447e59ecab0f222	CONS0002	P71959	2026-03-25	Raideur de la nuque, fièvre élevée, photophobie s...	Lésion mammaire ACR4 à BI-RADS 4, biopsie stéréot...
	CONS0003	P140873	2023-09-15	Hypersomnie diurne, apnées nocturnes, ronflements...	Apnées du sommeil modérées, polysomnographie conf...

Admin Fichier Objet Outils Aide

Explorateur d'Objets

- Catalogues
- Extensions
- Langages
- Publications
- Schémas (1)
 - public
 - Collationnements
 - Domaines
 - Fonctions
 - Fonctions d'agrégation
 - Fonctions déclenchées
 - Opérateurs
 - Procédures
 - Recherche Plein Texte
 - Recherche Plein Texte
 - Recherche Plein Texte
 - Séquences
 - Tables (4)
 - doctors
 - medications
 - patients
 - prescriptions
 - Tables Distantes
 - Types
 - Vues
 - Vues Matérialisées

public.prescriptions/labo_sante/admin@postgres-labo

100 lignes

Données Messages Notifications

Affichage des lignes : 1 à 100

	id [PK] character varying (50)	consultation_id character varying (50)	medication_id character varying (50)	date date	duration_days integer
3	R0003	CONS0003	M0006	2026-03-...	30
4	R0004	CONS0004	M0053	2025-10-...	21
5	R0005	CONS0005	M0011	2025-06-...	21
6	R0006	CONS0006	M0054	2025-05-...	30
7	R0007	CONS0007	M0058	2025-02-...	7
8	R0008	CONS0008	M0036	2023-10-...	21
9	R0009	CONS0009	M0032	2023-02-...	90
10	R0010	CONS0010	M0023	2024-10-...	7
11	R0011	CONS0011	M0035	2023-01-...	10
12	R0012	CONS0012	M0007	2026-04-...	14
13	R0013	CONS0013	M0038	2025-01-...	30
14	R0014	CONS0014	M0027	2024-04-...	45
15	R0015	CONS0015	M0038	2025-11-...	45
16	R0016	CONS0016	M0046	2024-01-...	10
17	R0017	CONS0017	M0002	2024-12-...	90
18	R0018	CONS0018	M0055	2023-08-...	7
19	R0019	CONS0019	M0037	2024-03-...	90
20	R0020	CONS0020	M0050	2025-11-...	30

Upgrade to Business Edition

PORTAINER.io
COMMUNITY EDITION

Home

local

Dashboard

Templates

Stacks

Containers

Images

Networks

Volumes

Events

Host

Administration

Containers

Container list

Containers

Search...

Start

Stop

Kill

Restart

Pause

Resume

Remove

Add container

☐	Name	State	Quick Actions	Stack	Image	Created	IP Address	Published Ports	Ownership
☐	mongo-express	running		labo-sante	mongo-express	2026-06-23 12:18:34	172.21.0.5	8081:8081	administrators
☐	mongodb	healthy		labo-sante	mongo:6	2026-06-23 12:18:33	172.21.0.2	27017:27017	administrators
☐	pgadmin	running		labo-sante	dpape/pgadmin4	2026-06-23 12:18:34	172.21.0.6	5050:80	administrators
☒	portainer	running		labo-sante	portainer/portainer-ce	2026-06-23 12:18:33	172.21.0.3	9000:9000	administrators
☐	postgres	healthy		labo-sante	postgres:15	2026-06-23 12:18:33	172.21.0.4	5432:5432	administrators

Items per page 10

6. Documentation d'utilisation

(Voir fichier read me)